Задача 4. Інференційна статистика

Частина 1. У цій частині ми розпочнемо з комп'ютерного та аналітичного моделювання для верифікації закону великих чисел та центральної граничної теореми (ЦГТ). Для аналізу поведінки користувачів мобільного додатку часто використовують експоненціальний розподіл. Проте для користувачів із високою лояльністю (де паузи між сесіями тривалі й нерівномірні) дані краще описуються Гамма-розподілом $\Gamma(k, \theta)$.

(а) Нехай істинний розподіл часу між сесіями користувачів є Гамма-розподілом із параметрами форми $k = 2$ та масштабу $\theta = 5$ (математичне сподівання $\mu = k\theta = 10$, дисперсія $\sigma^2 = k\theta^2 = 50$). Змоделюйте вибірки розміром $n = 5^1, 5^2, 5^3, \ldots, 5^8$ із зазначеного Гамма-розподілу. Для кожної вибірки обчисліть вибіркове середнє та вибіркову дисперсію. Побудуйте графік траєкторії вибіркових середніх як функцію від n (використовуйте логарифмічну шкалу на осі X). Який висновок ми можемо зробити з цього графіка, якщо пам'ятати про Слабкий закон великих чисел?

(б) Для кожної вибірки обчисліть вручну 95% довірчий інтервал для середнього значення μ та додайте його на графік. Зробіть це двічі: один раз із відомим теоретичним значенням σ, а другий — з оціненим вибірковим standard deviation (s). Обговоріть свої спостереження та надайте теоретичне пояснення отриманим результатам при малих і великих значеннях n.

(в) Змоделюйте $b = 1000$ вибірок розміром $n = 4$ із зазначеного вище асиметричного розподілу $\Gamma(2, 5)$. Для кожної вибірки оцініть середнє значення, дисперсію та збережіть їх. Побудуйте гістограму цих 1000 вибіркових середніх та гістограму 1000 вибіркових дисперсій.

(г) Якщо випадкові величини $X_1, \ldots, X_4$ підпорядковуються деякому ненормальному розподілу, то точний розподіл середнього значення або суми є невідомим. Однак ми все одно можемо аналітично обчислити математичне сподівання та дисперсію, тобто $E((X_1 + X_2 + X_3 + X_4)/4)$ та $Var((X_1 + X_2 + X_3 + X_4)/4)$. Обчисліть ці величини аналітично, використовуючи властивості розподілу, який ви обрали для моделювання в пункті (в).

(д) Додайте до гістограми середніх значень теоретичну щільність нормального розподілу з параметрами, що дорівнюють щойно обчисленим аналітичним величинам математичного сподівання та дисперсії. Порівняйте щільність із гістограмою. Чого ви очікуєте і чому (наведіть статистичні аргументи)? Що б сталося, якби ви збільшили кількість змінних у вибірці з 4 до, наприклад, 100? Обґрунтуйте відповідь за допомогою Центральної граничної теореми.

Частина 2. Метою цієї частини є глибше розуміння практичної процедури оцінювання методом максимальної правдоподібності (ML). Розглянемо процес реєстрації користувачів на сайті. Кожна спроба є випробуванням Бернуллі з невідомою ймовірністю успіху (конверсією) p. Маркетологи надали лог дій у вигляді єдиного датасету `app_metrics.csv`, де статус реєстрації зафіксовано у колонці `Registration_Success` (1 — реєстрація, 0 — вихід).

(а) Використовуючи Python, завантажте дані з колонки `Registration_Success` та виконайте одновибірковий критерій згоди Колмогорова-Смирнова у модифікації Лілієфорса (для випадку, коли параметри розподілу априорі невідомі й оцінюються за вибіркою), щоб перевірити, чи можна апроксимувати ці бінарні дані нормальним розподілом. Запишіть нульову та альтернативну гіпотези, статистику критерію та отримане значення p-value. Який висновок ми можемо зробити?

(б) Запишіть аналітичну функцію правдоподібності $L(p)$ та логарифмічну функцію правдоподібності $\ln L(p)$ для вибірки Бернуллі. Напишіть програмний код на Python для обчислення від'ємної логарифмічної функції правдоподібності (Negative Log-Likelihood):

$$-\ln L(p) = -\sum_{t=1}^{T} (r_t \ln p + (1 - r_t) \ln(1 - p))$$

де r_t — значення колонки `Registration_Success` для користувача t. Максимізуйте її відносно параметра p, використовуючи вбудовані функції оптимізації (`scipy.optimize.minimize`). Врахуйте граничні обмеження: $p \in [10^{-5}, 1-10^{-5}]$, щоб уникнути помилки обчислення логарифма нуля. Порівняйте отриману чисельну оцінку $\hat{p}_{MLE}$ з класичним вибірковим середнім $\bar{x}$.

(в) Використовуючи знайдену оптимальну оцінку параметра $\hat{p}$, обчисліть теоретичну ймовірність того, що:

- із наступних 20 відвідувачів сайту зареєструється рівно 5;
- із наступних 20 відвідувачів зареєструється щонайменше 8 користувачів;
- кількість реєстрацій серед 20 відвідувачів буде строго більшою за очікуване математичне сподівання $(20 \times \hat{p})$.

Нагадаємо, що для дискретних розподілів ймовірності обчислюються через вбудовані функції PMF та CDF біноміального розподілу.

Частина 3. Тут ми проведемо серію статистичних тестів для реальних даних продуктових метрик, які містяться у наданому файлі `app_metrics.csv`. Запустіть кожен тест програмно, але оформіть результати вручну, чітко вказавши: дві гіпотези (H_0 та H_1); аналітичну формулу для статистики критерію з підставленими числовими значеннями; область відхилення (критичну область); отримане значення p-value; ваше статистичне рішення та розгорнутий вербальний бізнес-висновок. Для всіх тестів використовуйте фіксований рівень значущості $\alpha = 5\%$.

(а) Продакт-менеджер стверджує, що очікуваний час утримання користувача (`Session_Time`) перевищує 15 хвилин. Чи можна це підтвердити за допомогою відповідного одностороннього параметричного критерію?

(б) Перевірте, чи суттєво відрізняється середня сума чеку (`Revenue`) користувачів платформи iOS від очікуваного чеку користувачів Android. Припустімо, що генеральні дисперсії невідомі і не обов'язково рівні (t-критерій Уелша).

(в) Ми висуваємо гіпотезу про те, що кількість переглядів сторінок (`Page_Views`) та підсумкова сума покупки (`Purchase_Amount`) не пов'язані між собою. Перевірте це твердження за допомогою критерію для коефіцієнта лінійної кореляції Пірсона.

(г) Тестуйте гіпотезу про те, що генеральна частка (пропорція) користувачів, які оформлюють платну підписку (`Subscription`), є статистично значущо вищою за 10%.

(д) Усі вищезазначені параметричні тести покладаються на обов'язкове припущення про нормальність розподілу ознак у генеральній сукупності. Перевірте це базове припущення для метрики `Revenue` за допомогою одновибіркового критерію Колмогорова-Смирнова у модифікації Лілієфорса. Використовуйте виключно вбудовані функції бібліотеки `statsmodels`, без ручних розрахунків.

Частина 4. Наступне завдання — перевірити за допомогою статистичного моделювання Монте-Карло, чи правильно досягається задана теоретична ймовірність помилки 1-го роду (розмір критерію α) для простого двостороннього тесту щодо середнього значення.

(а) Змоделюйте вибірку довжиною $n = 30$ із нормального розподілу з параметрами $\mu_0 = 100$ і $\sigma^2 = 25$. Тестується нульова гіпотеза $H_0 : \mu = 100$ проти двосторонньої альтернативи. Припустімо, що генеральна дисперсія є невідомою та має бути оцінена за вибіркою. Обчисліть значення тест-статистики за формулами; визначте аналітичну критичну область для рівня значущості $\alpha = 0.05$ і прийміть рішення щодо відхилення H_0.

(б) Змоделюйте незалежно $M = 5000$ вибірок розміром $n = 30$ кожна з параметрами $\mu_0 = 100$ і $\sigma^2 = 25$. Для кожної окремої вибірки i проведіть автоматичний тест та задайте індикаторний показник $p_i = 0$, якщо H_0 не відхиляється, і $p_i = 1$, якщо H_0 відхилено. Обчисліть значення емпіричного рівня значущості:

$$\hat{\alpha} = \frac{1}{M} \sum_{i=1}^{M} p_i$$

Порівняйте отримане значення $\hat{\alpha}$ з номінальним рівнем $\alpha = 0.05$. Очікуєте ви велику чи малу різницю між ними і чому? Обґрунтуйте висновок через відповідність умов експерименту теоретичним припущенням критерію Стьюдента.

Частина 5. Метою цієї частини є оцінка ймовірності помилки 2-го роду (а саме величини $1 - \beta$, яка визначає потужність тесту) для критеріїв згоди. Перевіримо чутливість одновибіркового критерію Колмогорова-Смирнова у модифікації Лілієфорса щодо його здатності розпізнавати та фіксувати відхилення даних від нормального розподілу, якщо насправді вони генеруються з розподілу Стьюдента.

- Змоделюйте $M = 1000$ вибірок обсягом $n = 80$ спостережень кожна з t-розподілу Стьюдента, послідовно змінюючи число ступенів свободи $df = 2, 3, \ldots, 60$. Для кожної вибірки запустіть тест Лілієфорса на перевірку нормальності та підрахуйте кількість випадків, коли нульова гіпотеза про нормальність була правильно відхилена для кожного фіксованого df. Поясніть, як саме ця величина

дозволяє оцінити потужність тесту. Побудуйте емпіричний графік залежності потужності від кількості ступенів свободи df (на осі X). Врахуйте, що при $df \to \infty$ t-розподіл асимптотично наближається до нормального. Зробіть статистичні висновки про надійність та чутливість критерію для великих значень df.