Задача 5: Лінійна регресія в Python

У цьому завданні ми працюватимемо з інструментами та методами візуалізації даних, а також обчисленням деяких простих характеристичних мір за допомогою бібліотек `pandas`, `statsmodels` та `scikit-learn`. Наша мета — застосувати всі базові техніки та зробити правильні висновки. Ми використовуємо набір даних Ames Housing, який доступний для завантаження на Kaggle:
`https://www.kaggle.com/c/house-prices-advanced-regression-techniques/overview`
або може бути завантажений напряму через репозиторії даних.

Застереження щодо завантаження даних: У датасеті Ames Housing абревіатура `NA` у категоріальних колонках позначає фізичну відсутність ознаки (наприклад, «немає гаража» чи «немає підвалу»), а не пропущене значення. Щоб `pandas` за замовчуванням не перетворював такі категорії на `NaN`, під час завантаження через `pd.read_csv()` використовуйте параметр `keep_default_na=False` або явно налаштуйте аргумент `na_values` (наприклад, `na_values=['']`).

Повний набір даних містить майже 3000 спостережень та 81 ознаку. Загальна мета полягає в тому, щоб пояснити ціни продажу `SalePrice`.

(1) Перед підгонкою моделі до даних спочатку детальніше розглянемо визначення змінних та вирішимо, чи потребують деякі з них окремої обробки. Розглянемо, наприклад, першу змінну `MSSubClass`. Вона набуває текстових (категоріальних) значень і очевидно не може бути включена в лінійну модель у вихідному вигляді. Існує два підходи до обробки такої змінної. Один підхід полягає в присвоєнні чисел від 1 до 16 кожному можливому результату (Label Encoding). Інший підхід полягає у створенні нових фіктивних змінних (One-Hot Encoding / Dummy variables), які дорівнюють одиниці для конкретного результату і нулю в іншому випадку. Обговоріть ці два підходи та запропонуйте, який із них є більш доречним у цьому випадку. Мотивуйте своє рішення, беручи до уваги номінальну, порядкову та кардинальну шкали зі статистики. Запустіть просту регресію `SalePrice` на `MSSubClass` у тому вигляді, в якому вона є (без кодування). Перевірте, як `statsmodels` або `scikit-learn` обробляє такий тип змінної, якщо вона передана як звичайний числовий тип (`int64`), та як її примусово змінити на категоріальну за допомогою `pd.Categorical` або формул `statsmodels.formula.api.ols` (C(MSSubClass)).

(2) Розгляньте такі числові пояснювальні змінні: `LotFrontage`, `LotArea`, `YearBuilt`, `BsmtFinSF1`, `BsmtUnfSF`. Побудуйте діаграму розсіювання (scatter plot) залежності `SalePrice` від цих змінних за допомогою `matplotlib` або `seaborn`. Проаналізуйте кожен графік та обговоріть потенційні проблеми, трансформації або розширення моделі, які дозволять врахувати виявлені закономірності. Пам'ятайте, що ви можете або трансформувати наявні змінні (наприклад, `np.log`), або створювати нові для фіксації нестандартних патернів.

(3) Підгоніть просту лінійну регресію за допомогою класу `OLS` з бібліотеки `statsmodels` без виконання обговорених вище трансформацій. Виберіть один із числових регресорів, наприклад, `LotArea`. Запишіть відповідну гіпотезу для t-тесту. Наведіть формулу для тест-статистики, поясніть компоненти цієї формули та вкажіть значення для цих компонентів із регресійного звіту (`summary()`). Оцініть якість підгонки (goodness-of-fit) моделі. Поясніть своїми словами різницю між R^2 та скоригованим (adjusted) R^2.

(4) Якщо ви хочете стверджувати, що змінна `MSSubClass` є незначущою, і використовуєте модель із фіктивними змінними, то вам необхідно перевірити одночасну (спільну) незначущість усіх даммі-змінних, що походять від факторної змінної `MSSubClass`. Запустіть тест для загальної лінійної гіпотези за допомогою методу `f_test()` у `statsmodels` та зробіть висновок про значущість `MSSubClass`. Запишіть матрицю та вектор, які необхідні для формулювання цієї гіпотези в межах лінійної моделі.

(5) Дайте економічну інтерпретацію параметрів для `LotArea`, першої фіктивної змінної для `MSSubClass` (це підступне питання!) та `BedroomAbvGr`. (Ігноруйте потенційну незначущість коефіцієнтів.) Як зміниться інтерпретація, якщо моделювати логарифм від `SalePrice` (`np.log(df['SalePrice'])`), використовуючи лог-лінійну специфікацію?

(6) Обчисліть 95% довірчий інтервал для параметра `LotArea` (використовуючи метод `conf_int()`) та поясніть його економічний зміст. Зв'яжіть довірчі інтервали з тестами значущості, тобто поясніть, як би ви використовували ці інтервали для прийняття рішення про значущість відповідних пояснювальних змінних? Довірчі інтервали обчислюються на основі припущення, що залишки (residuals) підпорядковуються нормальному розподілу. Чи виконується це припущення? Запустіть відповідний критерій згоди за допомогою `scipy.stats.shapiro` або `jarque_bera`.

(7) Більшість змінних можуть виявитися незначущими, тому нам слід знайти найменшу (найбільш економну) модель, яка все ще має хорошу пояснювальну здатність. Виберіть таку модель за допомогою покрокового відбору змінних (stepwise model selection), реалізувавши власний алгоритм на основі метрик AIC/BIC або скориставшись методами регуляризації Lasso з `sklearn.linear_model`. Детально поясніть, як цей метод/підхід працює у вашому коді. Працюйте з цією обраною моделлю на всіх наступних кроках.

(8) Іноді дані містять викиди (outliers), що спричиняє зсув в оцінках параметрів. Перевірте наявність викидів за допомогою графіків залишків, відстані Кука (Cook's distance) та важеля (leverage). Для обчислення цих показників скористайтеся класом `OLSInfluence` з бібліотеки `statsmodels`. Зверніть прискіпливу увагу на спостереження з найбільшим значенням важеля (leverage). Що саме робить це спостереження таким видатним (ви можете побудувати `sns.boxplot` для інтервальних змінних або порахувати частоти через `value_counts()`)?

(9) Часто в даних трапляються пропуски. Виберіть 5 випадкових рядків у наборі даних і видаліть значення для LotArea. Реалізуйте щонайменше два підходи для заповнення (імпутації) цих значень за допомогою інструментів pandas або класу SimpleImputer / IterativeImputer з sklearn.impute. Запишіть відповідні формули/модель та наведіть мотивацію для вашого підходу. Зауважте, що для імпутації слід використовувати повний набір даних, а не лише набір змінних після відбору ознак. **Зверніть увагу:** ваш алгоритм має обробляти лише дійсні пропуски (як-от у `LotFrontage` або ваші штучні пропуски в `LotArea`), а не структурні категорії `NA`, які ви мали зберегти як окремі факторні рівні.

(10) Тепер розглянемо модель із `SalePrice` та модель із log(`SalePrice`). Запустіть відповідний тест (наприклад, тест Девідсона-Маккіннона або порівняння через

трансформовані залишки), щоб вирішити, яка з моделей є кращою. Поясніть ідею цього тесту і чому ви не можете прийняти аналогічне рішення за допомогою простого порівняння критеріїв AIC/BIC, виданих `statsmodels` для цих двох моделей напряму.

(11) Ми хочемо оцінити прогнозну здатність побудованої регресії. Розглянемо повну модель та модель після відбору ознак. Порівняйте ці дві моделі за допомогою крос-валідації «залишення по одному» (`LeaveOneOut`) та 5-блочної крос-валідації (`KFold`) з бібліотеки `sklearn.model_selection`. Поясніть ідею цієї техніки за допомогою формул та зробіть висновок про прогностичну здатність обох моделей на основі метрики MSE.

Задача 6: Нелінійні регресії в Python

Нелінійна регресія пропонує гнучку техніку для моделювання складних взаємозв'язків. Ми хочемо пояснити ціну продажу `SalePrice` за допомогою року побудови `YearBuilt`. Для цієї мети використовуйте лише перші 500 спостережень з нашого `DataFrame`.

(а) Побудуйте двовимірну діаграму розсіювання (bivariate scatter plot) та оцініть відповідну лінійну (!) модель через `statsmodels` або `LinearRegression` з `sklearn`. Додайте лінію регресії на графік.

(б) Тепер оцініть відповідну нелінійну регресію (наприклад, експоненціальну або степеневу залежність) за допомогою функції `curve_fit` з бібліотеки `scipy.optimize`. Додайте криву регресії на графік і порівняйте (кількісно) якість підгонки нелінійної моделі з лінійною за допомогою метрик R^2 та MSE.

(в) Поясніть своїми словами, чому всі класичні тести та статистичні висновки (наприклад, точні t-розподіли для малих вибірок) не є прямо застосовними до оцінок нелінійного методу найменших квадратів (NLS), отриманих через `curve_fit`.

(г) Які проблеми з обчислювальною збіжністю (convergence) та перенавчанням можуть виникнути, якщо ми вирішимо побудувати складну нелінійну регресію, використовуючи одночасно всі наявні пояснювальні змінні у датасеті?